Documentação Técnica: Simulador de Impacto Orçamentário (Salvador – BA)

1. Visão Geral do Projeto

O que o projeto faz

O **Simulador de Impacto Orçamentário** é uma solução de Big Data e Machine Learning voltada para a gestão pública municipal de Salvador. A aplicação consolida séries temporais do desempenho hoteleiro e fiscal da cidade, permitindo simular, em tempo real, como variações no fluxo turístico (taxa de ocupação hoteleira, preço da diária média e a realização de grandes eventos) impactam diretamente a **Receita Turística Estimada** e a **Arrecadação Municipal do ISS** (Imposto Sobre Serviços) dos setores ligados ao turismo.

Qual problema ele resolve

A tomada de decisão na gestão pública do turismo frequentemente baseia-se em relatórios estáticos e dados retroativos. Gestores municipais enfrentam dificuldades para responder com precisão a perguntas estratégicas de planejamento orçamentário, tais como: *"Se investirmos em campanhas para elevar a ocupação hoteleira em 10% na baixa temporada, qual será o retorno real em arrecadação fiscal para o município?"*.

O simulador resolve essa incerteza ao transformar dados históricos em um modelo preditivo dinâmico, fornecendo aos tomadores de decisão um instrumento prático para quantificar o retorno fiscal e econômico de políticas públicas e grandes eventos na cidade.

Intenção do Projeto

O objetivo principal do produto final é entregar um **Dashboard Interativo** que sirva de ponte entre a inteligência de dados (Big Data e Aprendizado de Máquina) e a gestão pública estratégica, viabilizando o teste de cenários econômicos em tempo de execução sem complexidade técnica para o usuário final.

2. Bases de Dados Utilizadas

A base consolidada abrange **68 meses históricos (de janeiro de 2021 a agosto de 2026)** com granularidade mensal, unificando cinco datasets oficiais através da chave temporal ano_mes:

Arquivo CSV	Variável Utilizada	Descrição / Papel no Modelo
Taxa_ocupação.csv	taxa_ocupacao	Porcentagem média mensal de ocupação da rede hoteleira de Salvador. Variável explicativa de volume.
Diaria_media_RevPar.csv	diaria_media e revpar	Preço médio da diária (R$) e o RevPAR informado nos relatórios históricos. Variáveis explicativas de valor.
Fator_evento.csv	fator_evento	Peso categórico atribuído aos picos de demanda da cidade (0 para meses regulares, 1 para festivais, 2 para alta temporada e Carnaval).
Receita_turistica.csv	receita_turistica	Estimativa do montante financeiro total movimentado pelos turistas na cidade (Alvo Primário).
Receita_iss.csv	receita_iss	Arrecadação municipal do ISS nos setores de alojamento, agências, eventos e gastronomia (Alvo Secundário).

3. Backend e Ingestão de Dados

A arquitetura de backend opera inteiramente em Python no ambiente Google Colab, estruturada nas seguintes etapas funcionais:

- **Mecanismo de Ingestão Flexível:** O script verifica a existência da pasta /content/drive/MyDrive/Dados_turismo. Caso ausente, o sistema ativa uma rotina automatizada que aceita a submissão de um arquivo big data.zip contendo as bases em CSV.

- **Validação de Cobertura e Consistência Temporal:** Para evitar erros de modelagem, o pipeline verifica se os 5 CSVs compartilham exatamente a mesma sequência de meses e aplica a estrutura de PeriodIndex mensal. O

sistema interrompe a execução caso identifique lacunas temporais ou valores ausentes (NaN).

- **Engenharia de Atributos (*Feature Engineering*):**
    - **Cálculo Padronizado do RevPAR:** Para sanar divergências pontuais encontradas nas planilhas históricas, o sistema recalcula matematicamente em tempo de execução o RevPAR real:

      RevPAR Calculado = (Taxa de Ocupação /100) * Diária Média

    - **Sazonalidade Cíclica:** Extrai a variável temporal mes (1 a 12) diretamente do índice temporal para parametrizar o comportamento das estações do ano.

4. Machine Learning e Modelagem Preditiva

A inteligência preditiva foi desenvolvida com foco em regressão contínua sobre dados de séries temporais:

- **Algoritmo Selecionado:** RandomForestRegressor (300 estimadores), escolhido por lidar eficientemente com interações não-lineares entre diárias e ocupação, sem sofrer distorções causadas por picos atípicos (como o período do Carnaval).
- **Estrutura de Entrada e Saída:**
    - **Vetores de Entrada (X):** taxa_ocupacao, diaria_media, revpar_calculado, fator_evento e mes.
    - **Modelos Independentes (Y):** Treinamento de duas instâncias do modelo — uma dedicada à estimativa da receita_turistica e outra à arrecadação de receita_iss.
- **Validação Cruzada e Métricas de Erro:**
    - **Janela de Teste (*Hold-out*):** Isolamento dos 12 meses mais recentes da série (setembro de 2025 a agosto de 2026) exclusivamente para avaliação do desempenho.

- **Linha de Base (*Baseline*):** Comparação direta contra o método Ingênuo/Sazonal (repetição do valor observado no mesmo mês do ano anterior).

- **Indicadores:** Erro Absoluto Médio (MAE em Reais) e Coeficiente de Determinação (R^2).

5. Interface Gráfica Interativa (ipywidgets + Plotly)

A camada visual foi implementada utilizando a biblioteca ipywidgets acoplada a gráficos dinâmicos em Plotly:

Abas da Aplicação

1. **Simulador (Aba Principal):**

    a. **Controles:** Sliders parametrizados dinamicamente entre os limites mínimos e máximos da base (OCUPACAO_MIN a OCUPACAO_MAX e DIARIA_MIN a DIARIA_MAX), impedindo extrapolações fora da zona de aprendizado do Random Forest.

    b. **Cards de Impacto:** Exibição imediata das previsões monetárias acompanhadas por régua visual de posicionamento e variação percentual/absoluta frente à média histórica do mês selecionado.

    c. **Gráfico de Comparação:** Barras interativas que contrapõem os valores reais históricos daquele mês contra a barra amarela do cenário simulado.

2. **Histórico:** Gráficos de séries temporais, padrões médios de sazonalidade mensal, boxplots do fator de eventos e matriz de correlação estatística entre as variáveis.

3. **Sobre o Modelo:** Tabela detalhada de métricas de teste (MAE e R^2), gráfico de barras da importância relativa de cada variável nas decisões do modelo e o dicionário das bases consumidas.